

Difusión en Imágenes Médicas: Eliminación de Ruido y Generación de Patologías

Fernando Sánchez
Paini Juárez

April 4, 2025

Abstract

Este proyecto propone el uso de modelos de difusión (*Denoising Diffusion Implicit Models, DDIM*) para mejorar la calidad de imágenes médicas, específicamente radiografías. Mediante el proceso inverso de difusión, se busca eliminar ruido y artefactos en imágenes no nítidas, así como generar representaciones realistas de patologías. El modelo se basa en el ejemplo de *Diffusion Model* de Keras, adaptado para datos médicos. Los resultados demuestran aplicaciones prácticas en diagnóstico asistido y aumento de datos.

1. Motivación

Las imágenes médicas con ruido o baja resolución pueden dificultar el diagnóstico preciso. Métodos tradicionales como filtros Gaussianos suelen perder detalles críticos. Los modelos de difusión ofrecen un enfoque probabilístico para reconstruir señales subyacentes, preservando estructuras anatómicas. Además, la generación sintética de patologías permite entrenar modelos de clasificación en escenarios de datos limitados.

2. Planteamiento del Problema

Se define la tarea como un problema de **restauración de imágenes** y **generación condicional**:

- Eliminar ruido/artefactos en radiografías mediante el proceso inverso de difusión.
- Generar imágenes sintéticas de patologías (ej. nódulos pulmonares) para aumentar conjuntos de datos.

3. Construcción del Conjunto de Datos

Se utiliza el dataset **CheXpert**, que contiene radiografías de tórax anotadas con patologías. Preprocesamiento incluye:

- Normalización de intensidades a $[-1, 1]$.
- Aumento de datos: rotaciones aleatorias, recortes.
- Adición sintética de ruido Gaussiano y artefactos para entrenamiento.

4. Arquitectura del Modelo

El modelo de difusión se adapta para el procesamiento de imágenes utilizando una arquitectura basada en redes neuronales, específicamente a partir del modelo de difusión disponible en Keras¹. El proceso de difusión se modela de manera probabilística, donde el modelo aprende a eliminar el ruido y restaurar las imágenes originales de manera gradual.

¹<https://keras.io/examples/generative/ddpm/>

5. Entrenamiento y Evaluación

- Train/Val/Test: 70/15/15
- **Optimizador:** Adam.
- **Métricas:** PSNR, SSIM, y evaluación cualitativa.

6. Conclusión

Los modelos DDIM muestran potencial para aplicaciones médicas, combinando precisión y interpretabilidad.